

PREDICCIÓN

Aprendizaje Supervisado

Clasificación

Árboles Decisión

Random Forest

K-Nearest Neighbor

SVM

Naïve Bayes

Redes Neuronales

Regresión

Lineal

No-Lineal

Logística

DESCRIPCIÓN

Aprendizaje No-supervisado

Asociación

Reglas de Asoc

Apriori

Segmentación

K-Means, Jerárquicos

DBSCAN, HDBSCAN

Autoencoders

Restricted Boltzman
Machines (RBM)

ANÁLISIS

Semi-supervisado

COMPARACIÓN

Word Embedding

Cálculo Distancia


Transformers

DBSCAN


Density –Based Spatial Clustering of Applications with Noise

Técnica de clusterizado espacial basada en densidad para aplicaciones con ruido

Precio de Casa en Pesos (1:100,000)




Antigüedad de la Construcción en Años




Objetivo: identificar patrones en el set de datos, para ajustar potencialmente sus estrategias de ventas.

Los puntos representan todas ventas que ha realizado la inmobiliaria a lo largo de su existencia




Punto representa la venta de una casa de aproximadamente 12 años de antigüedad que ha sido vendida aproximadamente en un millón trescientos mil pesos




De acuerdo a la distribución de los puntos podemos observar regiones de agrupamientos de puntos....

Veremos como el algoritmo DBSCAN los puede detectar y a la vez aprender cómo funciona esta técnica.



1 paso: DBSCAN selecciona un punto (cualquiera) y DBSCAN trata de determinar si el punto se encuentra en una región densa.




La región densa se define a partir de un parámetro llamado épsilon.

Región densa. Área dentro del círculo con radio o épsilon que se establece desde el punto que se seleccionó.

Ejemplo $\epsilon = 2$ es la distancia = 2 con esto se define los límites de la vecindad del punto en particular.

épsilon (ϵ) = 2


**Distancia que
marca los límites
del Vecindario**



Paso 2: Verificar ¿Qué tan densa es la región?: Para ello se requiere contar todos los puntos que se efectivamente se encuentran dentro del círculo.


Se tienen 13 puntos -> 12 morados y 1 amarillo. Por lo tanto, tenemos una vecindad de 13 puntos.

Para saber si es densa o no se debe definir un umbral. Como, por ejemplo, un umbral de 10 puntos significará que cualquier región que posea 10 o más puntos en la región es una región densa.



puntos = 10

Densidad mínima del Vecindario







Si hay densidad,
entonces es
punto CORE
(central)

Paso 3: Si la región es densa: el punto seleccionado se le conoce como punto core o punto central. Por lo tanto, el punto formará parte de un cluster.


El algoritmo de seleccionar un punto hasta acá se repite hasta haber detectado los puntos core.

Paso siguiente, tomar otro punto y revisar su vecindad. En este caso se toma un valor adyacente repitiendo el proceso.






Se toma el
siguiente punto
arbitrariamente




Caso: El punto no cumple con el umbral
para ser considerada región densa y por
tanto ese punto no se marca como
punto core sino se marca como ruido.

Si NO hay
densidad,
entonces
RUIDO




Todo punto se
etiqueta como
CORE o **RUIDO**

Precio de Casa en Pesos (1:100,000)



Resultado:
los puntos
han sido
etiquetados




¿Hay puntos
contiguos
a los CORES?

Paso 4: revisar puntos contiguos a puntos core: puntos que no cumplían con el umbral que no pertenecen a áreas densas.


Segunda fase del algoritmo DBSCAN. Se verifican aquellos puntos de ruidos que son alcanzables por puntos core. Por lo cual, estos puntos alcanzables serán incluidos en el cluster.

Ahora, se
identifican
puntos RUIDO
alcanzables
desde CORES
y se unen al
Cluster


Paso 4: revisar puntos contiguos a puntos core: realizamos el mismo procedimiento anterior.....




**Resultado de
añadir puntos
contiguos a los
CORES**



Resultado de
añadir **puntos**
contiguos a los
CORES




Regiones épsilon contiguas



Cada sección
épsilon-contigua
representa un
Cluster



3 Clusters



Para un $\epsilon = 2$ y para un umbral de 10 puntos.

La empresa está vendiendo distintos grupos de propiedades:

Amarillo: está vendiendo un grupo que propiedades que son recientes en costos relativamente económicos.

Verde: está vendiendo otro grupo de propiedades que está siendo muy caras pero también muy viejas.

Roja: Hay una tendencia de vender propiedades más baratas conforme las propiedades se van haciendo más viejas

Así la inmobiliaria elabora estrategias de ventas para cada una de estas propiedades

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.cluster import DBSCAN

# Cargar datos
datos = np.loadtxt("casas.csv", delimiter=",")

# Identificar Clusters
clusters = DBSCAN(eps=2, min_samples=10).fit_predict(datos)
print(clusters)


# Gráfica de matplotlib para mostrar los Clusters
plt.figure(figsize=(7.5, 7.5))
plt.scatter(datos[:, 0], datos[:, 1], c=clusters, s=100)
plt.xlabel("Antigüedad de la Construcción en Años")
plt.ylabel("Precio de Casa en Pesos (1:100,000)")
plt.box(False)
plt.show()
```





```

[-1 -1 -1  0  0  0  0 -1  1  1 -1 -1 -1 -1  0  0  0  0  0  0  1  1  1 -1
-1  0  0  0  0  0  0  0  1  1  1  1  1 -1  0  0  0  0  0  0  0  0  1  1
 1  1  1  1 -1 -1  0  0  0  0  0  0  0  0  1  1  1  1  1  1  1  0  0  0
 0  0  0  0  0  0  0  1  1  1  1  1  1 -1  0  0  0  0  0  0  0  0  0  0
 1  1  1  1  1  1  1  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  0  1
 0  0  0  0  0  0  0  0  0 -1  1  1  1  0  0  0  0  0  0  0  0  0  0
-1  1  1  0  0  0  0  0  0  0  0  0  0  0  0  0 -1  0  0  0  0  0  0
 0  0 -1 -1 -1  0  0  0  0  0  0  0  0  0  0  0 -1  0  0  0  0  0  0
 0  0 -1  0  0  0  0  0  0  0  0 -1 -1  0  0  0  0  0  0  0  0  0  0
 0  0  0  0  0  0  0  0  0 -1  2 -1  0  0  0  0  0  0  2  2  0  0  0
 0  0  0  0  0  0  2  2  2  2  2  2  2  0  0  0  0  0  0  0  0  0  0
 2  2  2  2 -1 -1 -1  0  2  2  2  2  2  2  2  2  2  2 -1 -1  0  0  0
 2  2  2  2  2 -1 -1 -1 -1 -1 -1  2  2  2  2 -1 -1  2  2 -1]

```



Jugar con DBSCAN <https://www.naftaliharris.com/blog/visualizing-dbscan-clustering>



DBSCAN

Algoritmo

1. Se eligen 2 parámetros y un valor épsilon (ϵ) y un número de puntos (minP).
2. Se elige un punto aleatorio del espacio
3. Se buscan todos aquellos puntos, que estén a una distancia igual o menor a épsilon del punto inicial.
 - Si hay más de minP puntos (incluyendo el inicial), se eligen sólo minP
4. Se expande el cluster, revisando todos los nuevos puntos, y se ve si ellos forman un cluster, incrementando el cluster recursivamente.
5. Cuando se acaban los puntos, se toma un nuevo punto y se comienza de nuevo.
6. Aquellos puntos que no entran (por estar más distantes de ϵ de los otros) se les considera “ruido” y quedan aislados.