

Evaluación Sumativa N°1

El objetivo principal: extraer información útil y patrones de los datos históricos del naufragio del Titanic.

Realiza el siguiente procedimiento de Obtención del conocimiento KDD para el caso Titanic.

1. Identificación del Objetivo del Problema. Descubrir qué factores influyeron en la supervivencia de los pasajeros del Titanic. Incluir una sección en Colab como, por ejemplo:

✓ Caso Titanic - Teresa Tapia V1

1. El problema del negocio ¿qué factores que influyeron en la supervivencia de los pasajeros del Titanic?

2. Carga el data set y describe el conjunto de datos (Naturaleza del Dato):

- a. Describe cada atributo del set de datos. Utiliza la siguiente información.

1. PassengerId: Clave única asociada a cada pasajero.
2. Survived: indica si una persona sobrevivió o murió
3. Pclass: La clase en la que viajó cada pasajero
4. Name: El nombre del pasajero
5. Sex: Género del pasajero
6. Age: Edad del pasajero
7. SibSp: Número de hermanos/esposa(o), que viajaban con el pasajero
8. Parch: Número de padres e hijos que viajaban con el pasajero
9. Ticket: El número del boleto
10. Fare: La tarifa pagada por el boleto
11. Cabin: El número de compartimiento donde se alojó el pasajero
12. Embarked: esta variable hace referencia al lugar donde el pasajero abordó el Titanic

- b. Obtiene la siguiente información:

- i. cantidad de registros y cantidad de columnas
- ii. cantidad de registros totales por columna y el tipo de datos
- iii. Identifica la naturaleza del dato:

1. Consulta los primeros registros y clasifica a cada atributo con su tipo de datos, cualitativo(categorico) o cuantitativo, nominal u ordinal, numérico o continuo y si esta codificado o no.

Variables	tipo de datos	clasificación	subclasificación	interpretación origen
PassengerId	int64	Númerico	Discreto	

2. Consulta tanto variables categóricas y numéricas:

- a. Cantidad de valores únicos por atributo
usa `df['NOMBRECAMPO'].nunique()`
- b. Obtener los valores únicos por atributo
Usa `df['NOMBRECAMPO'].unique()`

- c. Realizar instrucciones en Python para completar la tabla del punto 1 como se muestra a continuación y obtener un análisis de ello.

Variables	tipo de datos	clasificación	subclasificación	valores	cantidad valores	codificada a numérico	interpretación origen
PassengerId	int64	Número	Discreto				
Survived	int64	Número	Discreto	0, 1	2	SI	Nominal Binario (Sobrevivió, No Sobrevivió)

Nota: para representar la tabla, se incluye un ejemplo para crear la tabla en la carpeta sumativa 1.

- d. Realizar instrucciones en Python para realizar otra tabla con la cantidad de registros por atributo, cantidad de valores únicos y cantidad de nulos. Realiza un análisis.


Variables	tipo de datos	clasificación	subclasificación	Cantidad de registros con valores	Cantidad valores únicos	Cantidad de Nulos
PassengerId	int64	Número	Discreto	891	891	0
Survived	int64	Número	Discreto	891	2	

- c. Para cada atributo grafica un histograma (solo si es posible) y realiza un análisis inicial de frecuencias.
3. Realizar Limpieza y análisis exploratorio del dato. Utiliza visualización de datos y análisis estadístico.
- Evaluar registros duplicados y tomar decisiones y acciones. Justificar
 - Evaluar valores faltantes y tomar decisiones y acciones. Justificar
 - Evaluar outliers y tomar decisiones y acciones. Justificar
 - Evaluar atributos irrelevantes y tomar decisiones y acciones. Justificar
 - Realizar análisis estadístico a través de medidas de tendencia central, como moda, mediana y media y realiza un análisis con el resultado de haber aplicado la función describe. Analiza columna a columna. Elabora graficas que permiten realizar análisis de los datos y justifica.

Considera algo como lo siguiente y obtén valores y gráficas:

Variables	clasificación	subclasificación	codificada a numérico	interpretación origen	Moda (Aplica a Todos)	Media (Aplica a numéricos)	Mediana (numéricos y ordinales)
PassengerId	Número	Discreto			Aplica -> No aplica Dato único	Aplica -> sin sentido	Aplica -> sin sentido

Revisa esta imagen para recordar



Nota: entre las gráficas incluye:

- a. Distribución de pasajeros por clase, edad y género.
 - b. Tasas de supervivencia globales y segmentadas por diferentes características demográficas.
 - c. Comparación de tasas de supervivencia entre diferentes clases y géneros.
4. Conclusión: realiza un resumen de los hallazgos más importantes y posibles implicaciones de los resultados.